Ferramentas de IA para pesquisas em regulação

Uma nota metodológica

Lucas Thevenard | Março 2026

Por que IA em estudos regulatórios?

- A regulação é **construída**, **justificada**, **contestada** e **revisada** por meio de textos.
- Os registros públicos (Diário Oficial, SEI, sistemas das agências) são verdadeiras minas de ouro de informação textual, mas:
  - Os dados estão desestruturados;
  - A informação dispersa e em forma de prosa oferece desafios técnicos à pesquisa.

Novas ferramentas de análise textual (sobretudo com o avanço dos LLMs)

- Três “famílias” de solução para análise de texto:
  i. Representações estatísticas do texto
  ii. Classificador especializado (supervisionado) OU Fine Tuning do Modelo
  iii. Codificação assistida por LLM (prompting)

Representações estatísticas e treinamento de modelos baseados em LLMs

Representações estatísticas do texto

- Transformação do texto em um vetor numérico (para uso em modelos estatísticos), processo também chamado de *feature extraction*
- **Modelos de saco de palavras** (TF-IDF): capturam apenas informações básicas do vocabulário do texto.
- **Modelos baseados em embeddings** (BERT, GPT, etc): capturam relações sintáticas e semânticas muito mais complexas, a depender do modelo treinado.
    - Alguns LLMs, como o GPT da OpenAI, possuem APIs por meio dos quais é possível gerar a representação estatística do texto (na minha tese usei embeddings do GPT-3).

[3]: gpt_df

[3]:

	consultation_id	comment_id	response_classification	label	dim_0	dim_1	dim_2	dim_3	dim_4	dim_5	...	dir
0	2020-4_1_3	2020-4_1_3_2354_91225_215	Within Scope	1	-0.051665	0.007054	-0.018452	-0.008952	0.010026	0.039429	...	0
1	2018-8_1_4	2018-8_1_4_2155_83465_313	Within Scope	1	-0.010849	0.055276	-0.015514	0.019065	-0.001684	0.004587	...	0
2	2021-6_2_1	2021-6_2_1_2510_96917_20	Within Scope	1	-0.018534	0.006539	-0.018973	0.019862	0.010110	-0.003032	...	0
3	2020-4_1_3	2020-4_1_3_2354_91147_145	Within Scope	1	-0.049575	0.005313	-0.016874	-0.006176	0.009786	0.042612	...	0.
4	2024-2_1_2	2024-2_1_2_20207_209600_17	Within Scope	1	-0.007543	0.035393	-0.023567	0.018289	0.014987	-0.002221	...	0
...	...	...	...	...	...	...	...	...	...	...	...	
1493	2025-1_1_3	2025-1_1_3_20292_212983_9	Out of Scope	0	-0.036144	-0.015623	-0.015025	0.008524	-0.022024	0.008564	...	-0
1494	2025-1_1_3	2025-1_1_3_20292_213001_12	Out of Scope	0	-0.034488	-0.024371	-0.019448	-0.002639	-0.008027	0.006576	...	-0
1495	2025-1_1_3	2025-1_1_3_20292_212923_14	Out of Scope	0	-0.027786	-0.015101	-0.012750	-0.014039	0.009682	0.014450	...	-0
1496	2025-1_1_3	2025-1_1_3_20292_212924_29	Out of Scope	0	-0.028192	-0.014880	-0.012806	-0.011875	0.010358	0.015628	...	-0
1497	2025-1_1_4	2025-1_1_4_20290_212692_1	Out of Scope	0	-0.015256	0.035137	-0.007969	0.012012	-0.013980	0.030384	...	-0.

1498 rows × 3076 columns

Treinamento de classificadores

- Modelo preditivo:
  - São usados algoritmos de machine learning para treinar o modelo em um subconjunto de dados.
    - Nesse etapa, são definidos intervalos para hiperparâmetros do algoritmo e é usado um processo de k-folding para selecionar os melhores parâmetros.
    - Uma vez treinado, o modelo é testado com dados que não fizeram parte do treinamento.
    - Por fim, o modelo é validado com dados que não estavam nem no treinamento, nem no teste.

[11]:
```
from sklearn.neighbors import KNeighborsClassifier
```

[12]:
```
knn = KNeighborsClassifier()

params_knn = {'n_neighbors': np.arange(1, 16),
              'metric': ["cosine", "euclidean"]}
```

[13]:
```
%%time
knn, grid_knn, report_knn = test_cfl_hyperparams(
    clf=knn,
    params_dict=params_knn,
    X_train=X_train,
    y_train=y_train,
    X_test=X_test,
    y_test=y_test,
    scoring=scoring,
    refit='accuracy',
    k_fold=10
)
```

```
Selected by 'accuracy': {'metric': 'cosine', 'n_neighbors': np.int64(1)}
CV mean accuracy: 0.8877
```

```
Test set metrics:
  accuracy            : 0.8815
  balanced_accuracy   : 0.8815
  precision           : 0.8992
  recall              : 0.8593
  f1                  : 0.8788
  roc_auc             : 0.8815
  average_precision   : 0.8430

Classification report:
              precision    recall  f1-score   support

           0       0.87      0.90      0.88       135
           1       0.90      0.86      0.88       135

    accuracy                           0.88       270
   macro avg       0.88      0.88      0.88       270
weighted avg       0.88      0.88      0.88       270



######################
# Out of Scope = 0  #
# Within Scope = 1  #
######################


Confusion matrix:
[[TN  FP]
 [FN  TP]]
[[122  13]
 [ 19 116]]
CPU times: user 376 ms, sys: 198 ms, total: 574 ms
Wall time: 7.64 s
```

Treinamento independente por feature extraction vs. Fine Tuning de um LLM

1. Feature extraction (embeddings + classificador)

Arquitetura: Texto -> LLM (embeddings) -> Classificador supervisionado

- O LLM é usado apenas como **extrator de representações**
- O vetor de **embeddings** vira input para um modelo de machine learning tradicional (ex.: KNN, regressão logística, SVM, random forest)
- **Somente o classificador é treinado**

Treinamento independente por feature extraction vs. Fine Tuning de um LLM

2. Fine-tuning do LLM

Arquitetura: Texto → LLM ajustado → classe

- O próprio **modelo de linguagem é treinado novamente**
- Os **pesos internos do LLM são atualizados**
- O modelo aprende **diretamente a tarefa**

Comparação: Feature extraction vs Fine-tuning

Aspecto	Embeddings + Classificador	Fine-tuning
Custo computacional	baixo	alto
Quantidade de dados	menor	maior
Complexidade técnica	simples	maior
Treinamento	rápido	mais lento
Controle do modelo	maior interpretabilidade	menor
Performance potencial	boa	geralmente maior
Atualização do LLM	não	sim

Quando usar embeddings + classificador

- ✓ datasets pequenos
- ✓ pesquisa aplicada
- ✓ modelos interpretáveis
- ✓ pipelines rápidos

Quando usar fine-tuning do LLM

- ✓ tarefas complexas
- ✓ grande volume de dados
- ✓ necessidade de máxima performance
- ✓ aplicações de produção

Adapter training – um meio termo entre *feature extraction* e *fine-tuning*

Arquitetura: Texto → LLM layer → Adapter → LLM layer → Adapter → saída

- Os **pesos originais do LLM ficam congelados**
- Apenas os **adapters são treinados**

Vantagens

✓ treina **muito menos parâmetros**
✓ preserva o conhecimento do modelo base
✓ permite múltiplas tarefas com o mesmo LLM

Relação do Adapter Training com outras técnicas modernas

Adapter training faz parte da família **PEFT (Parameter-Efficient Fine-Tuning)**.

Outras técnicas similares:

- **LoRA**
- **Prefix tuning**
- **Prompt tuning**

Usando IA como assistente de pesquisa

Uma alternativa: LLM-assisted coding

- Até agora vimos abordagens que **adaptam modelos** para tarefas específicas. Essas abordagens tratam o LLM (ou suas features) como **objeto de treinamento**.
- Outra possibilidade: Usar o LLM diretamente como **assistente de pesquisa**.

  Arquitetura: Texto → prompt estruturado → LLM → variável codificada

- Por essa metodologia, não treinamos nem adaptamos o modelo, apenas pedimos para ele analisar o texto e extrair a informação desejada de forma estruturada (como faríamos com um ser humano).

LLM-assisted coding

Abordagem metodológica baseada em **prompt engineering + validação humana**.

O pesquisador fornece ao modelo:

- definição do constructo
- instruções de codificação
- exemplos ou critérios decisórios
- formato estruturado de resposta

Estratégias de Prompt Engineering

- **Quanto à contextualização por exemplos**:
  - **Zero-shot prompting**: O modelo recebe *apenas a instrução da tarefa*, sem exemplos (embora possam ser definidos o contexto, o papel do modelo, etc).
  - **Few-shot prompting**: O prompt também inclui *exemplos de input → output* que serão observados antes da tarefa.
- **Quanto ao modelo de resposta**:
  - **Chain-of-thought prompting**: O modelo é instruído a *explicitar o raciocínio antes da resposta final*.
  - **Structured prompting**: O prompt exige *um formato específico de resposta*.

Vantagens do LLM-assisted coding

- Replica técnicas humanas de pesquisa que já são familiares (análise de conteúdo, classificação subjetiva/qualitativa e intercoder reliability test).
- Não exige alto conhecimento técnico (mas algum conhecimento em programação é útil, para automatizar e escalar a tarefa).
- Não exige dados classificados, muito menos onerosa de partida (torna-se necessário apenas classificar a amostra de validação).

Desvantagens do LLM-assisted coding

- Menor acurácia/qualidade das classificações.
- Engenharia de prompt pode ser menos replicável em outros contextos.

Caso empírico: consultas públicas da Anatel

- Unidade: contribuições escritas + resposta da agência (proxy de influência)
- Variáveis do artigo:
  - **Participante**: grupo de interesses do participante.
  - **Preferência (direção) regulatória**: pro-regulatory vs. de-regulatory.
  - **Tipo de argumento**: econômico, legal, técnico.
  - **Influência (proxy)**: fully accepted / partially accepted / rejected (e “out of scope”).

Evidências no caso da Anatel: resultados da minha tese de doutorado

Participantes

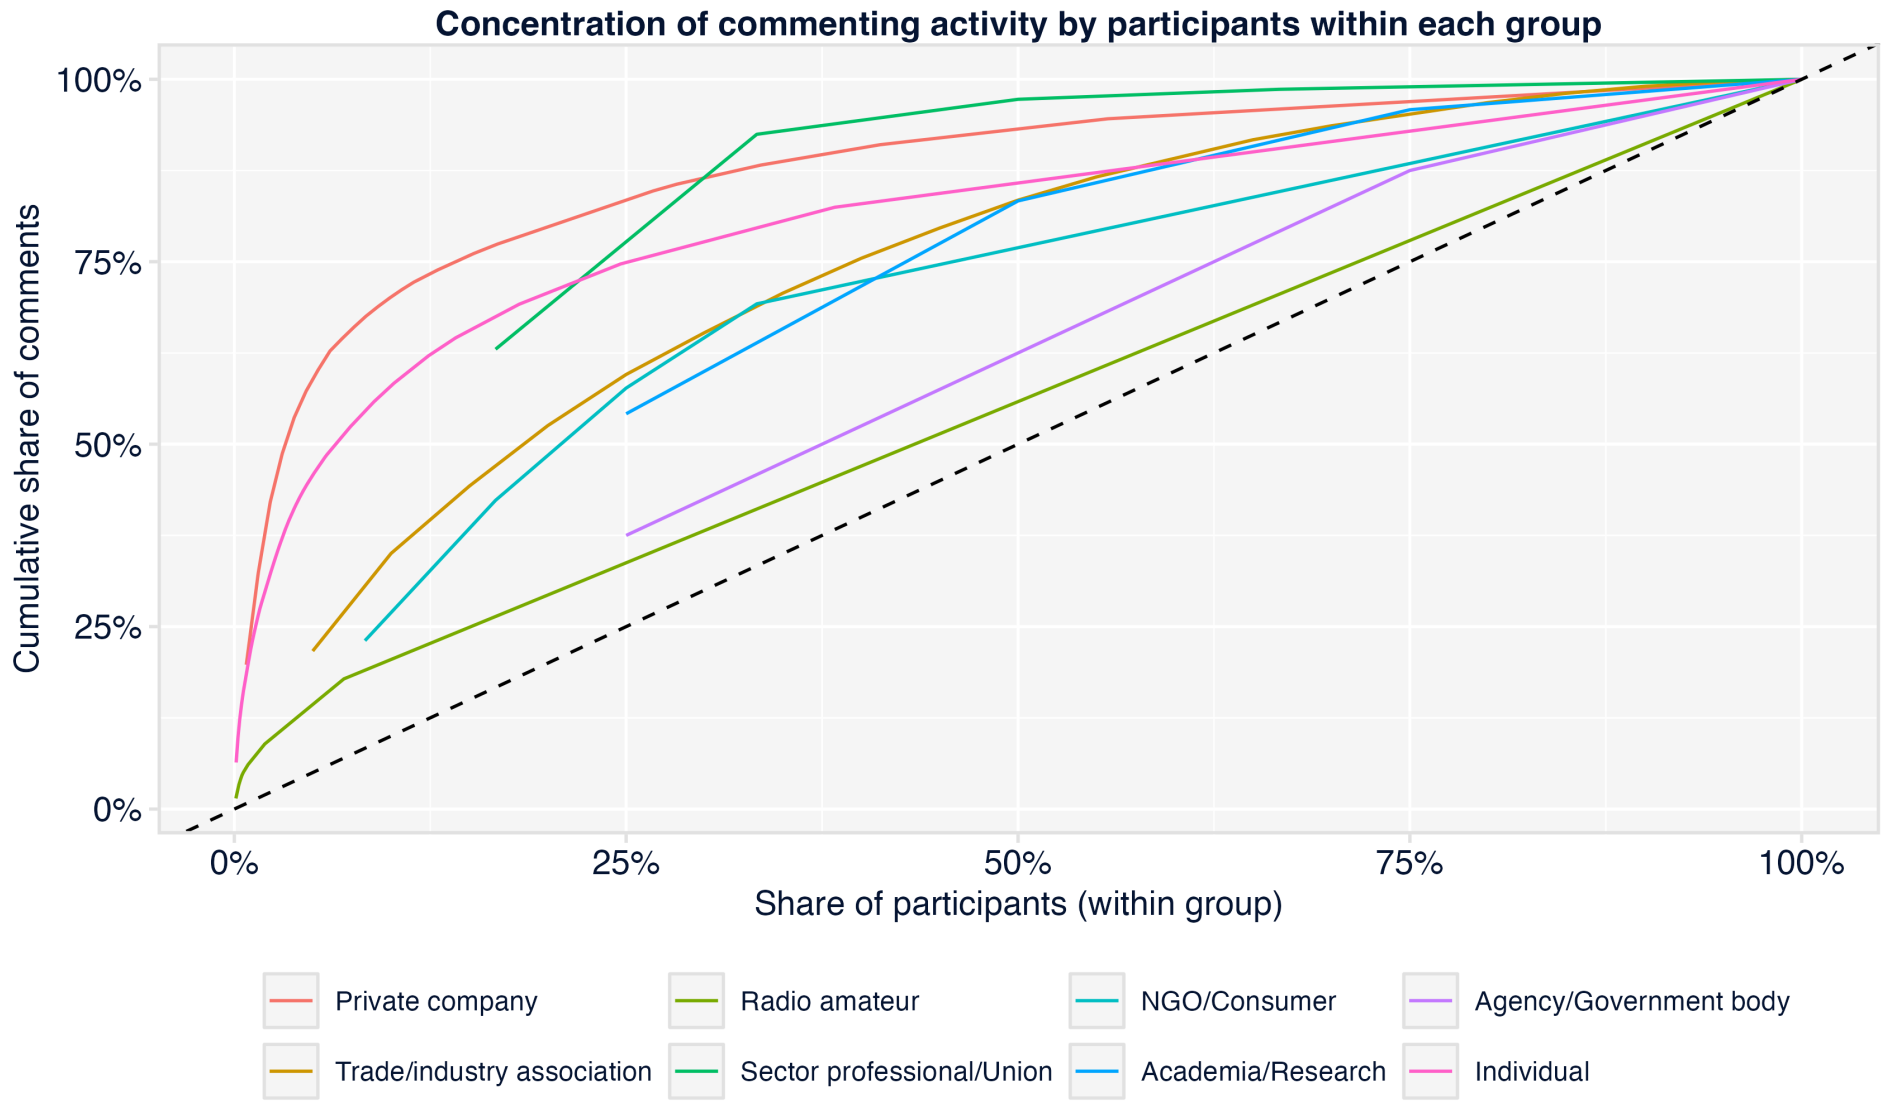
Concentration of commenting activity by participants within each group
Cumulative share of comments
100%
75%
50%
25%
0%
0%
25%
50%
75%
100%
Share of participants (within group)
Private company
Radio amateur
NGO/Consumer
Agency/Government body
Trade/industry association
Sector professional/Union
Academia/Research
Individual

Preferência regulatória (direção)

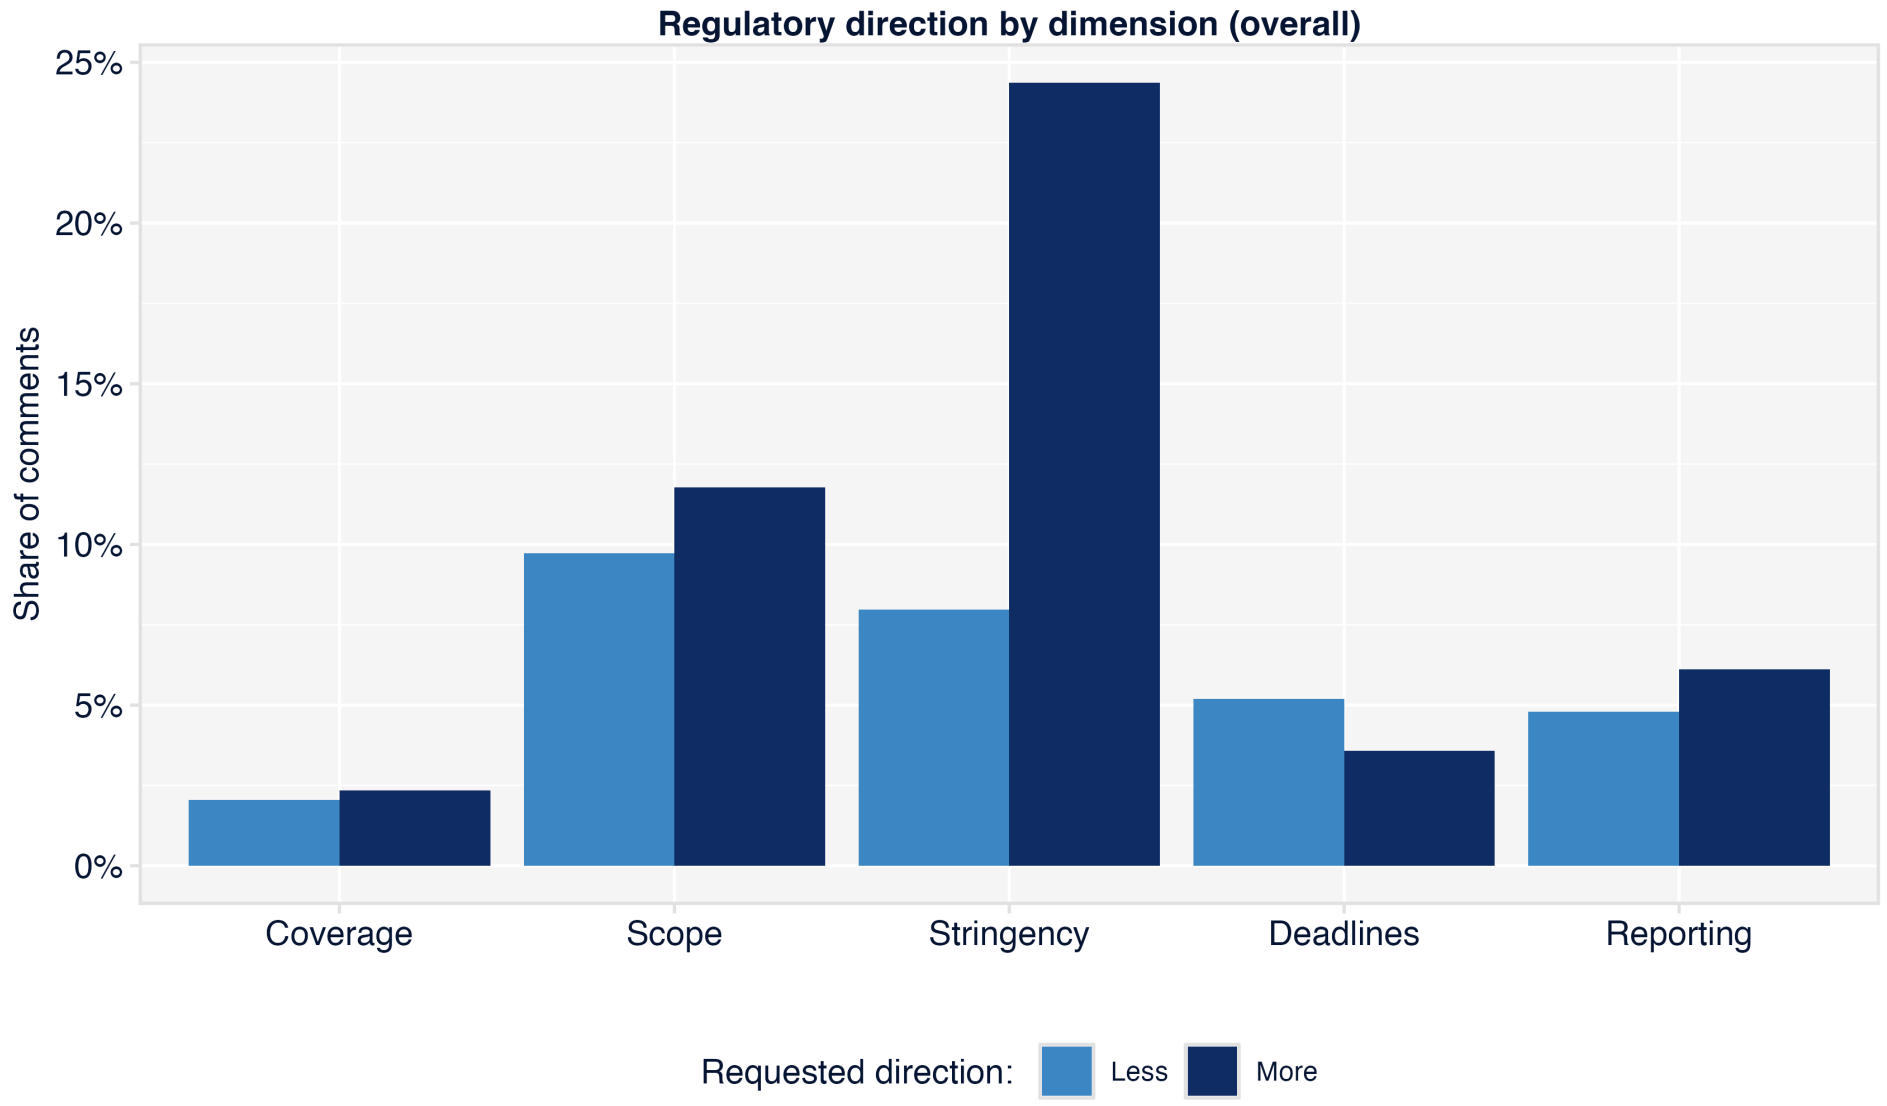
Regulatory direction by dimension (overall)
Share of comments
25%
20%
15%
10%
5%
0%
Coverage
Scope
Stringency
Deadlines
Reporting
Requested direction:
Less
More

Table 3 – Regulatory direction dimensions addressed in the comments

Number of dimensions addressed in each comment	Number of comments	Percentage of Comments
0 dimensions	2284	39.3%
1 dimension	2726	46.9%
2 dimensions	631	10.9%
3 dimensions	151	2.6%
4 dimensions	22	0.4%
5 dimensions	0	0.0%

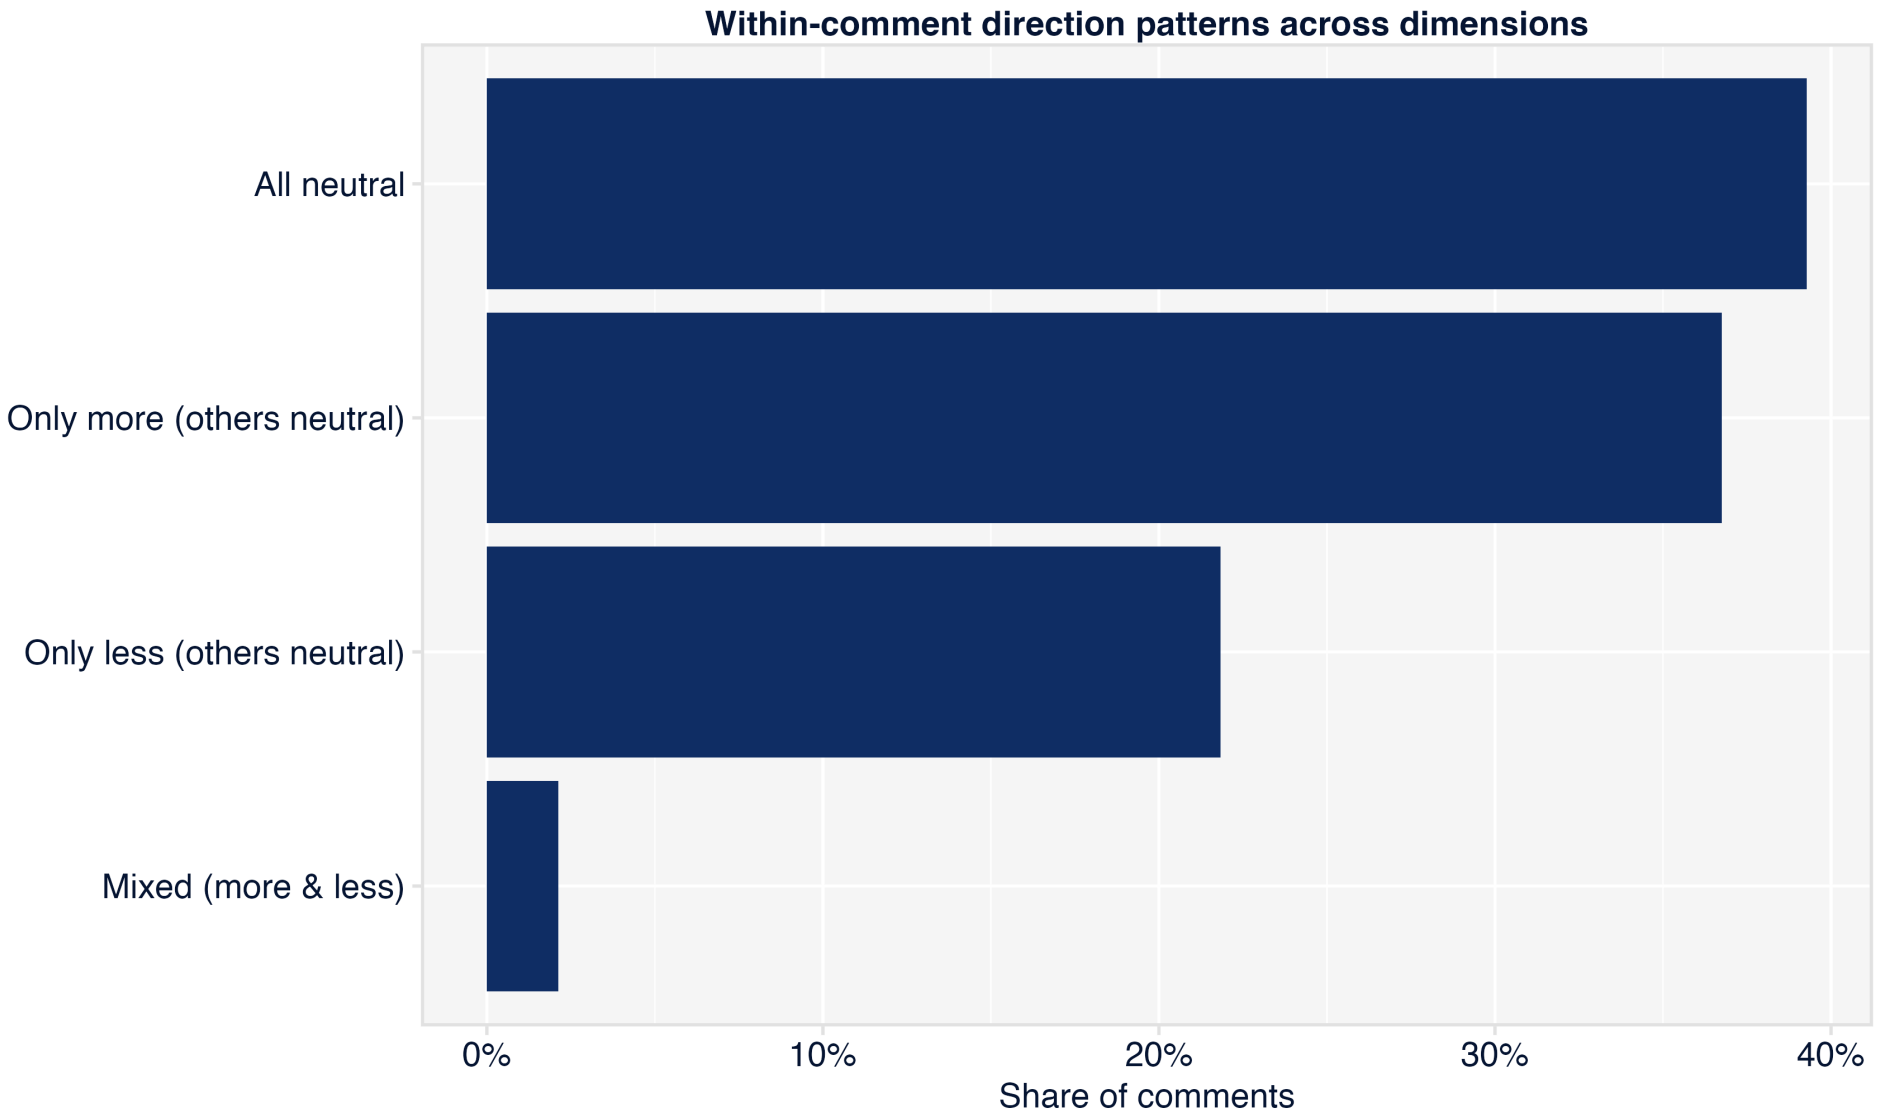
Within-comment direction patterns across dimensions
All neutral
Only more (others neutral)
Only less (others neutral)
Mixed (more & less)
0%
10%
20%
30%
40%
Share of comments

Ferramentas de IA para pesquisas em regulação

Justificativa (tipos de argumento)

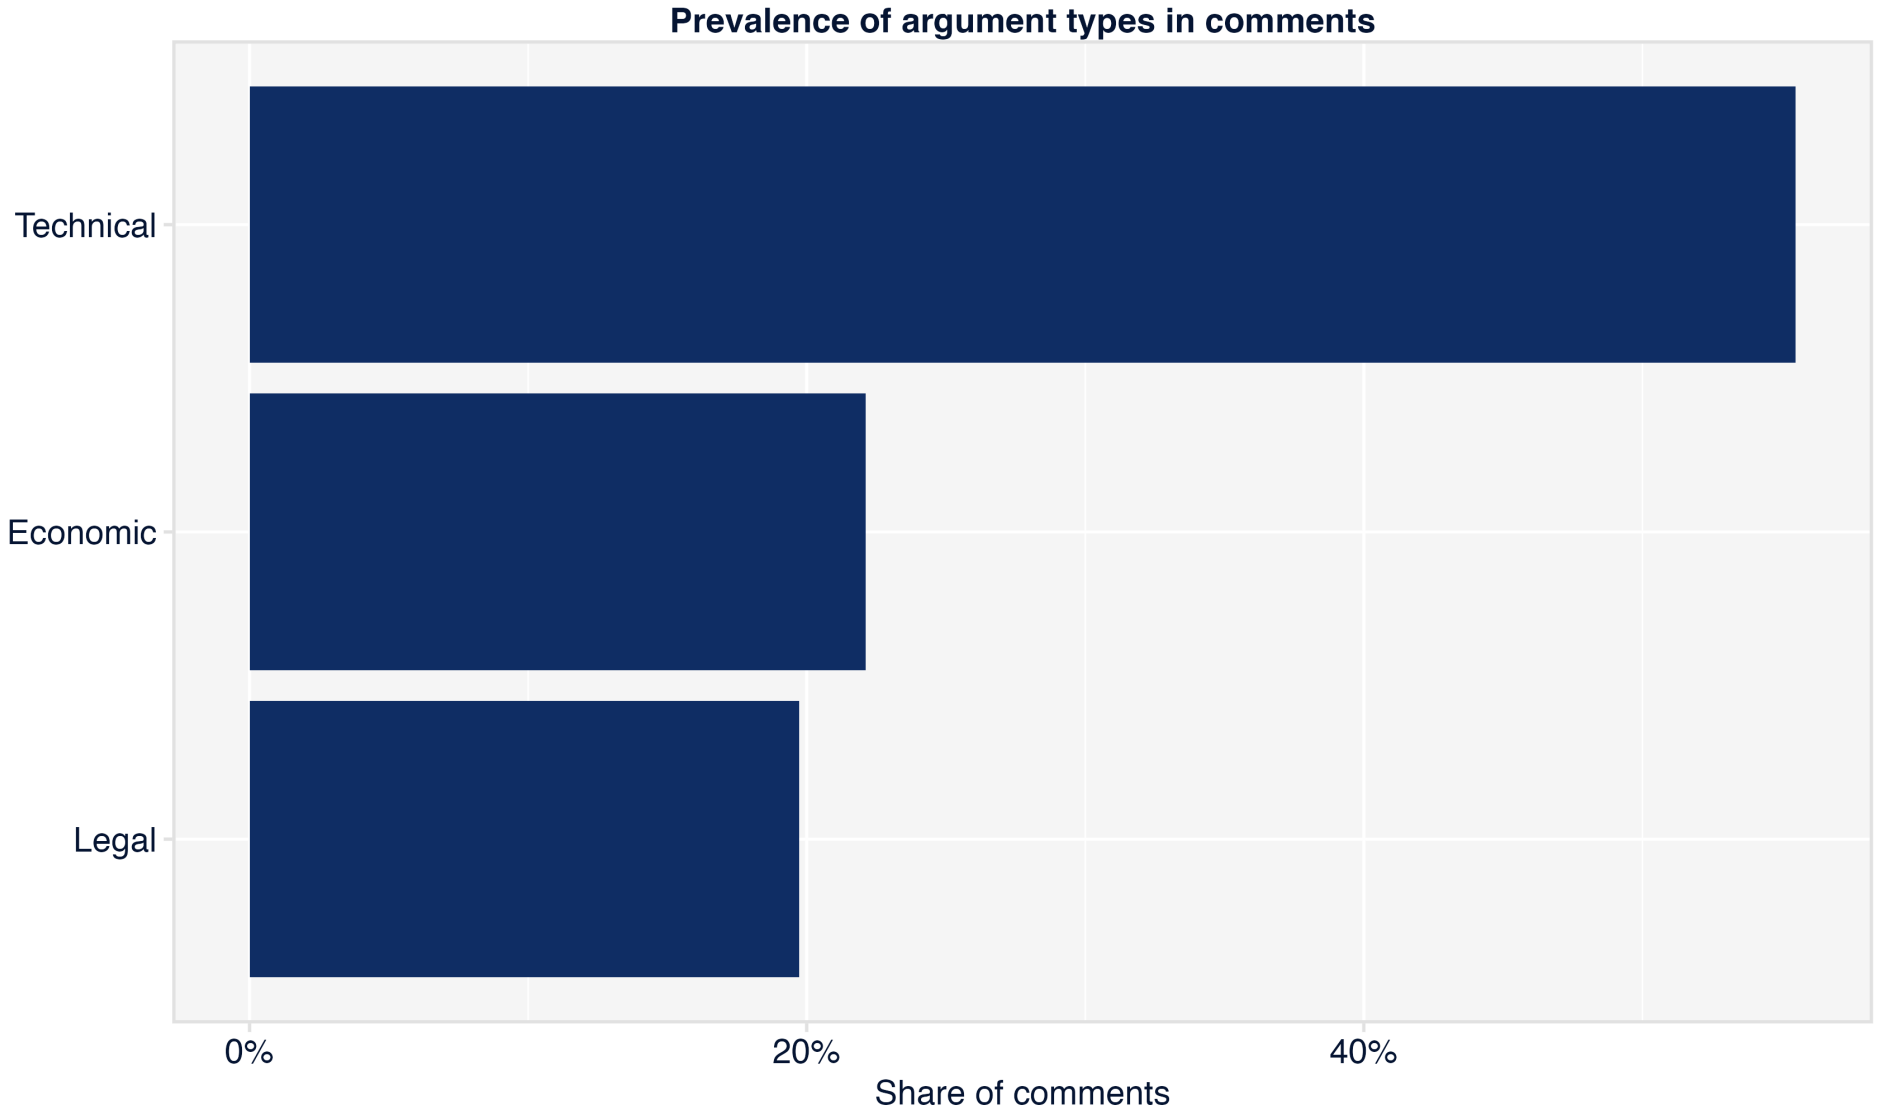
Prevalence of argument types in comments
Technical
Economic
Legal
0%
20%
40%
Share of comments

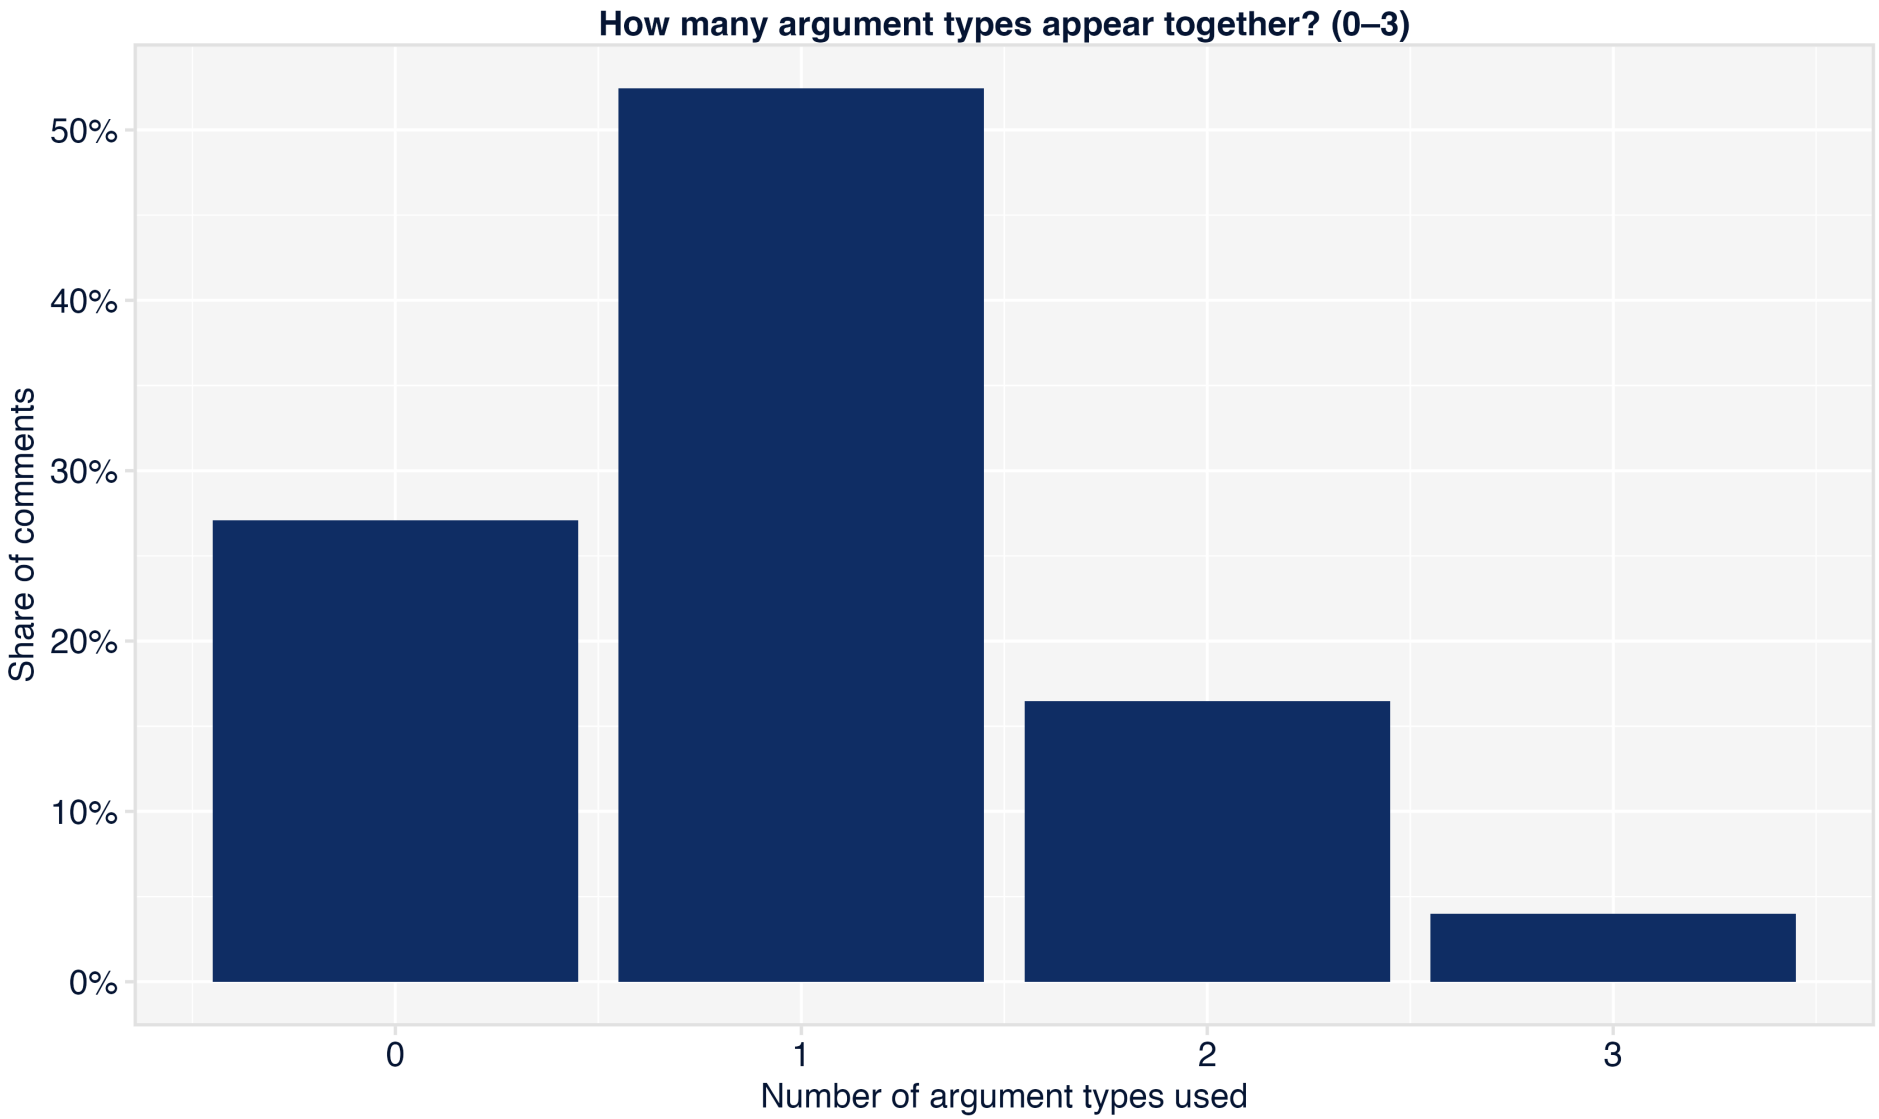
How many argument types appear together? (0–3)
Share of comments
50%
40%
30%
20%
10%
0%
0
1
2
3
Number of argument types used

Table 4 – Concurrence of types of arguments

A	B	N Both	Jaccard (A,B)	P(B | A)	P(A | B)
Economic	Legal	451	0.228	0.351	0.393
Economic	Technical	688	0.18	0.535	0.213
Legal	Technical	514	0.133	0.448	0.159

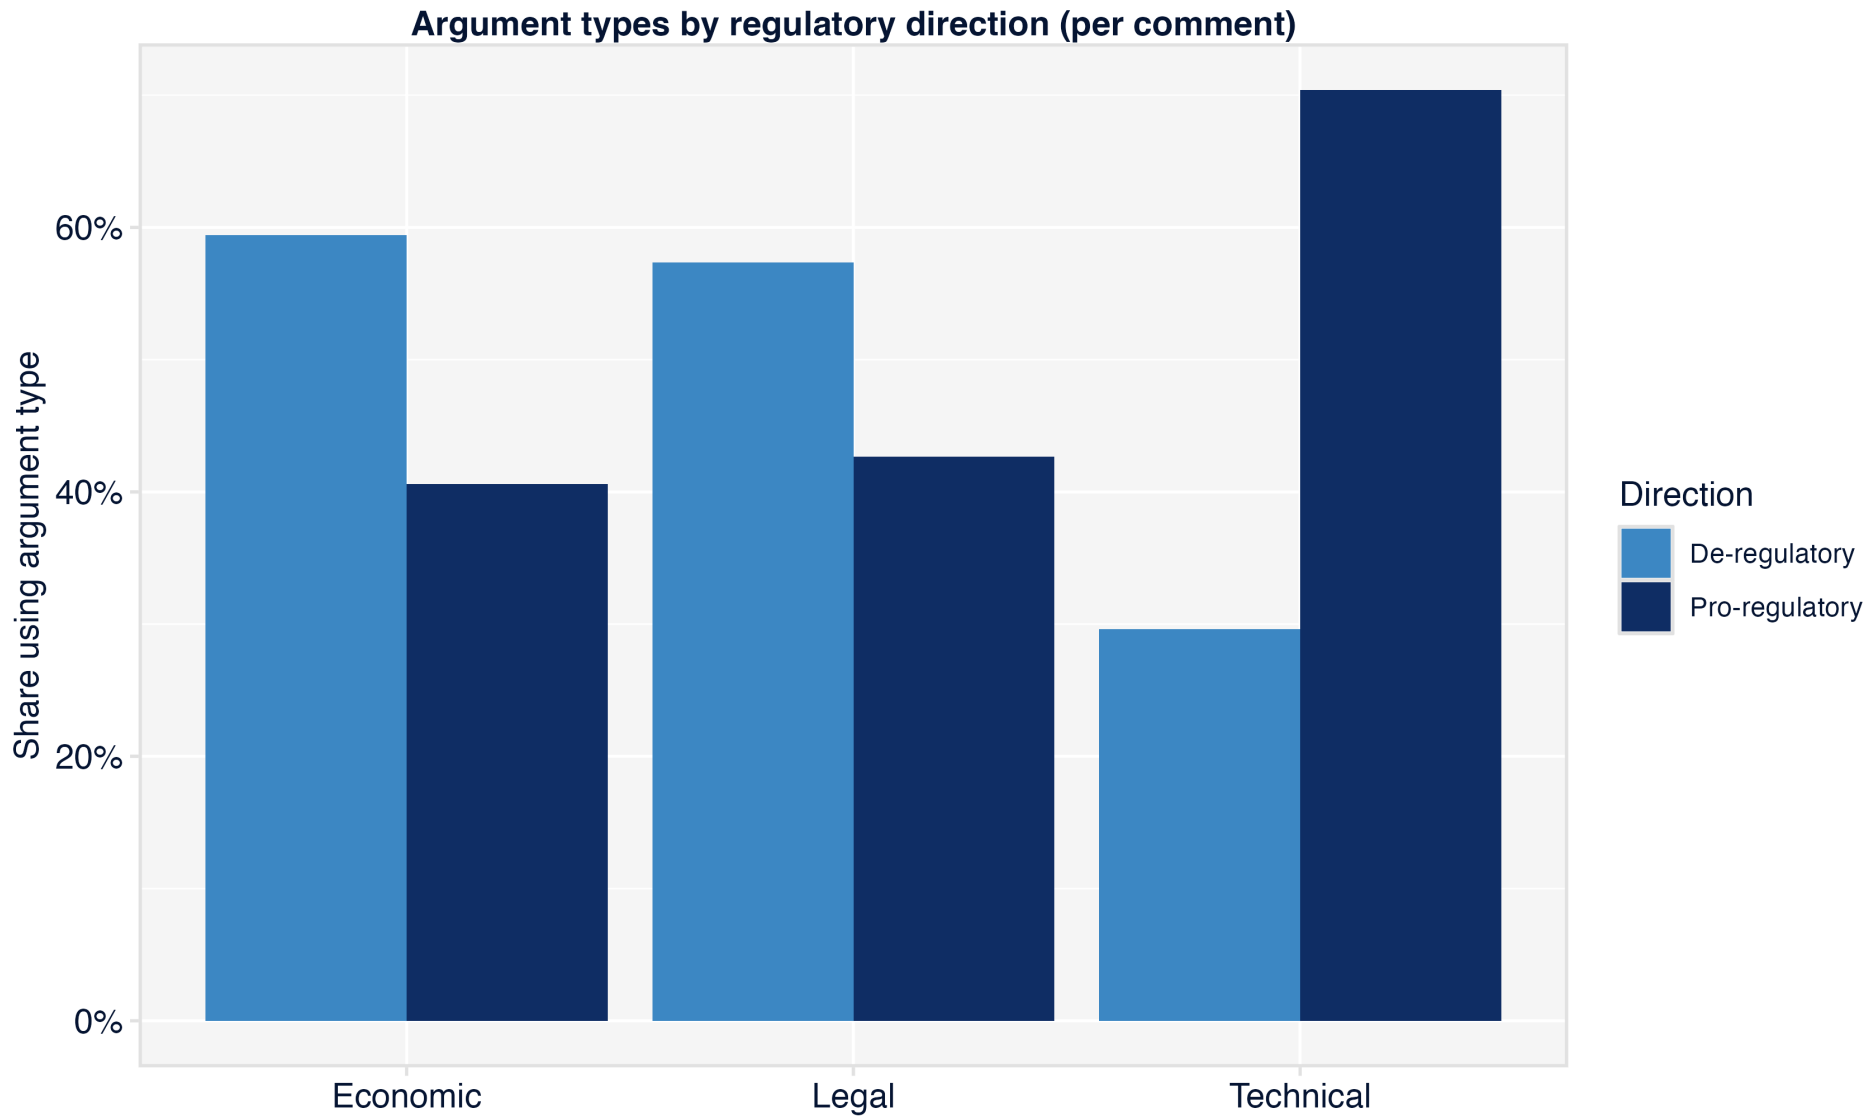
Argument types by regulatory direction (per comment)
Share using argument type
60%
40%
20%
0%
Economic
Legal
Technical
Direction
De-regulatory
Pro-regulatory

Impacto

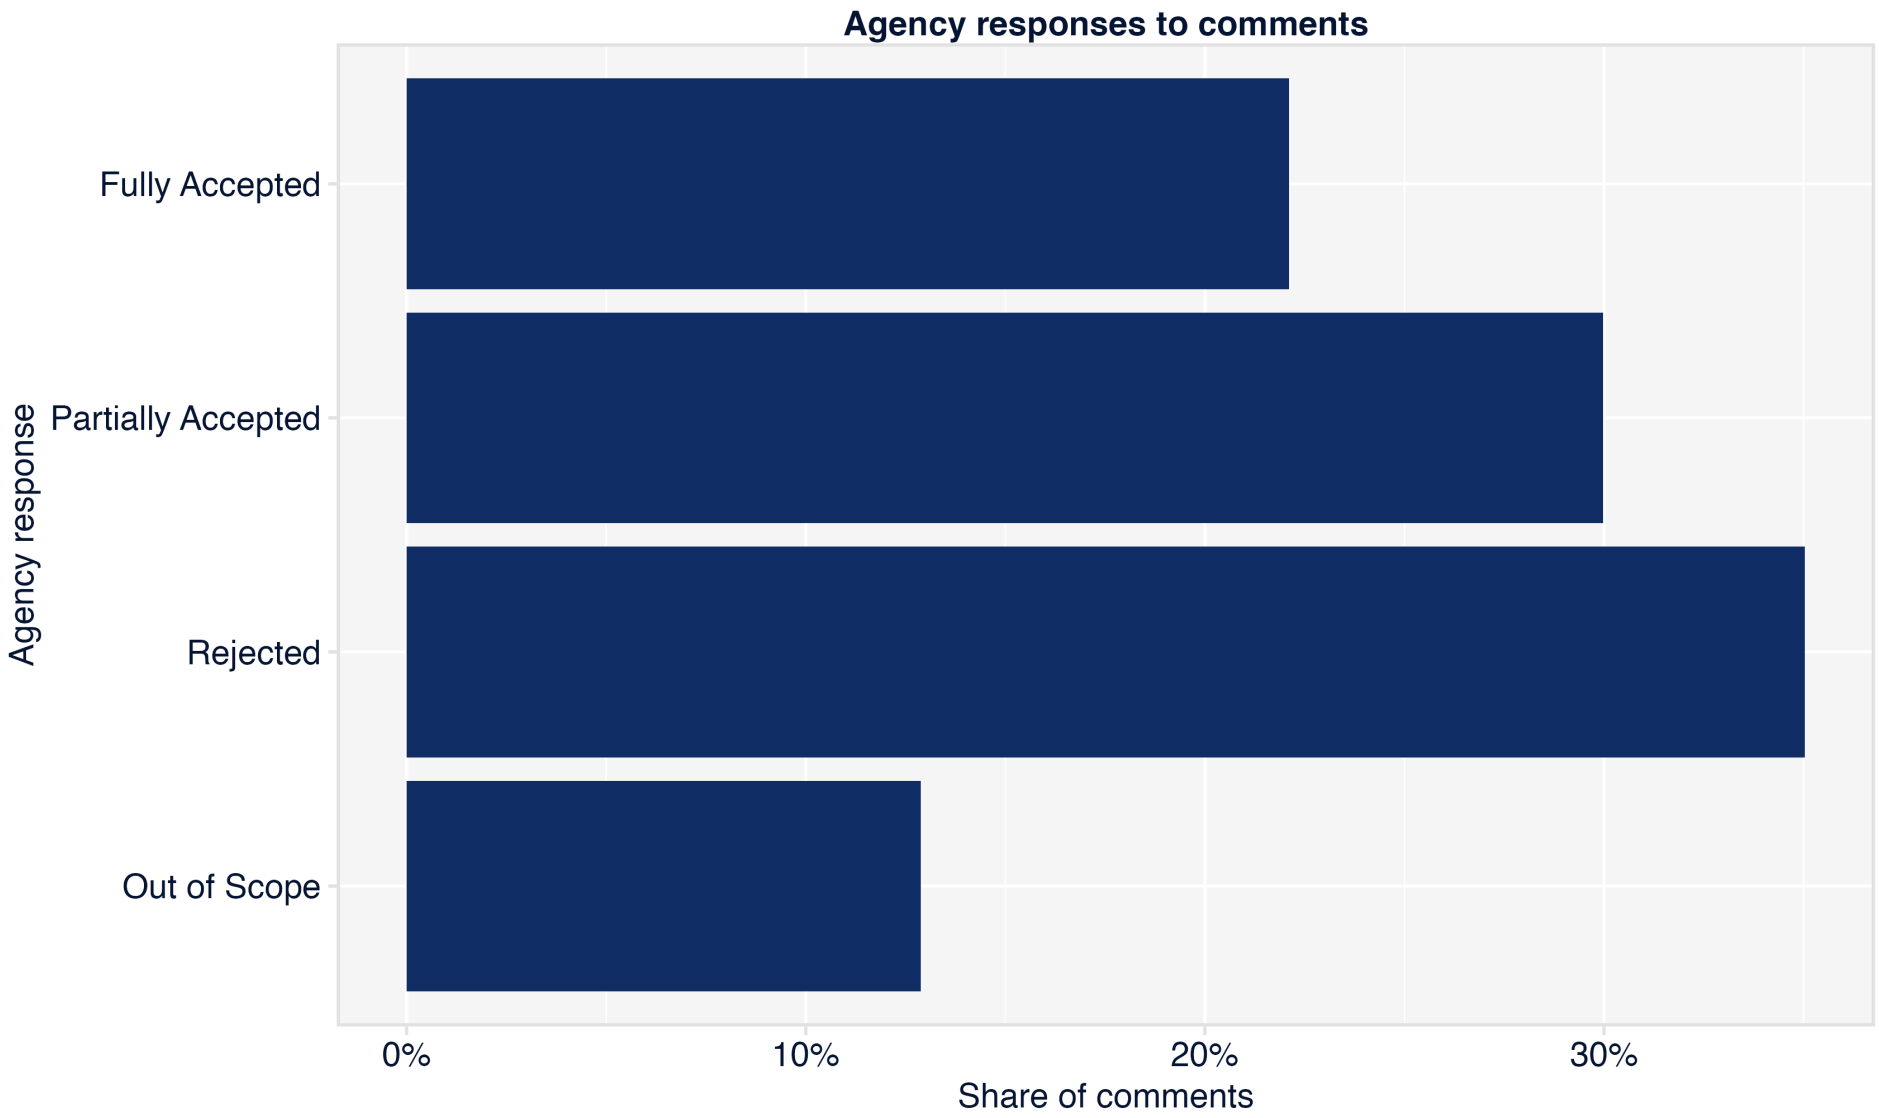
Agency responses to comments
Fully Accepted
Partially Accepted
Rejected
Out of Scope
Agency response
0%
10%
20%
30%
Share of comments

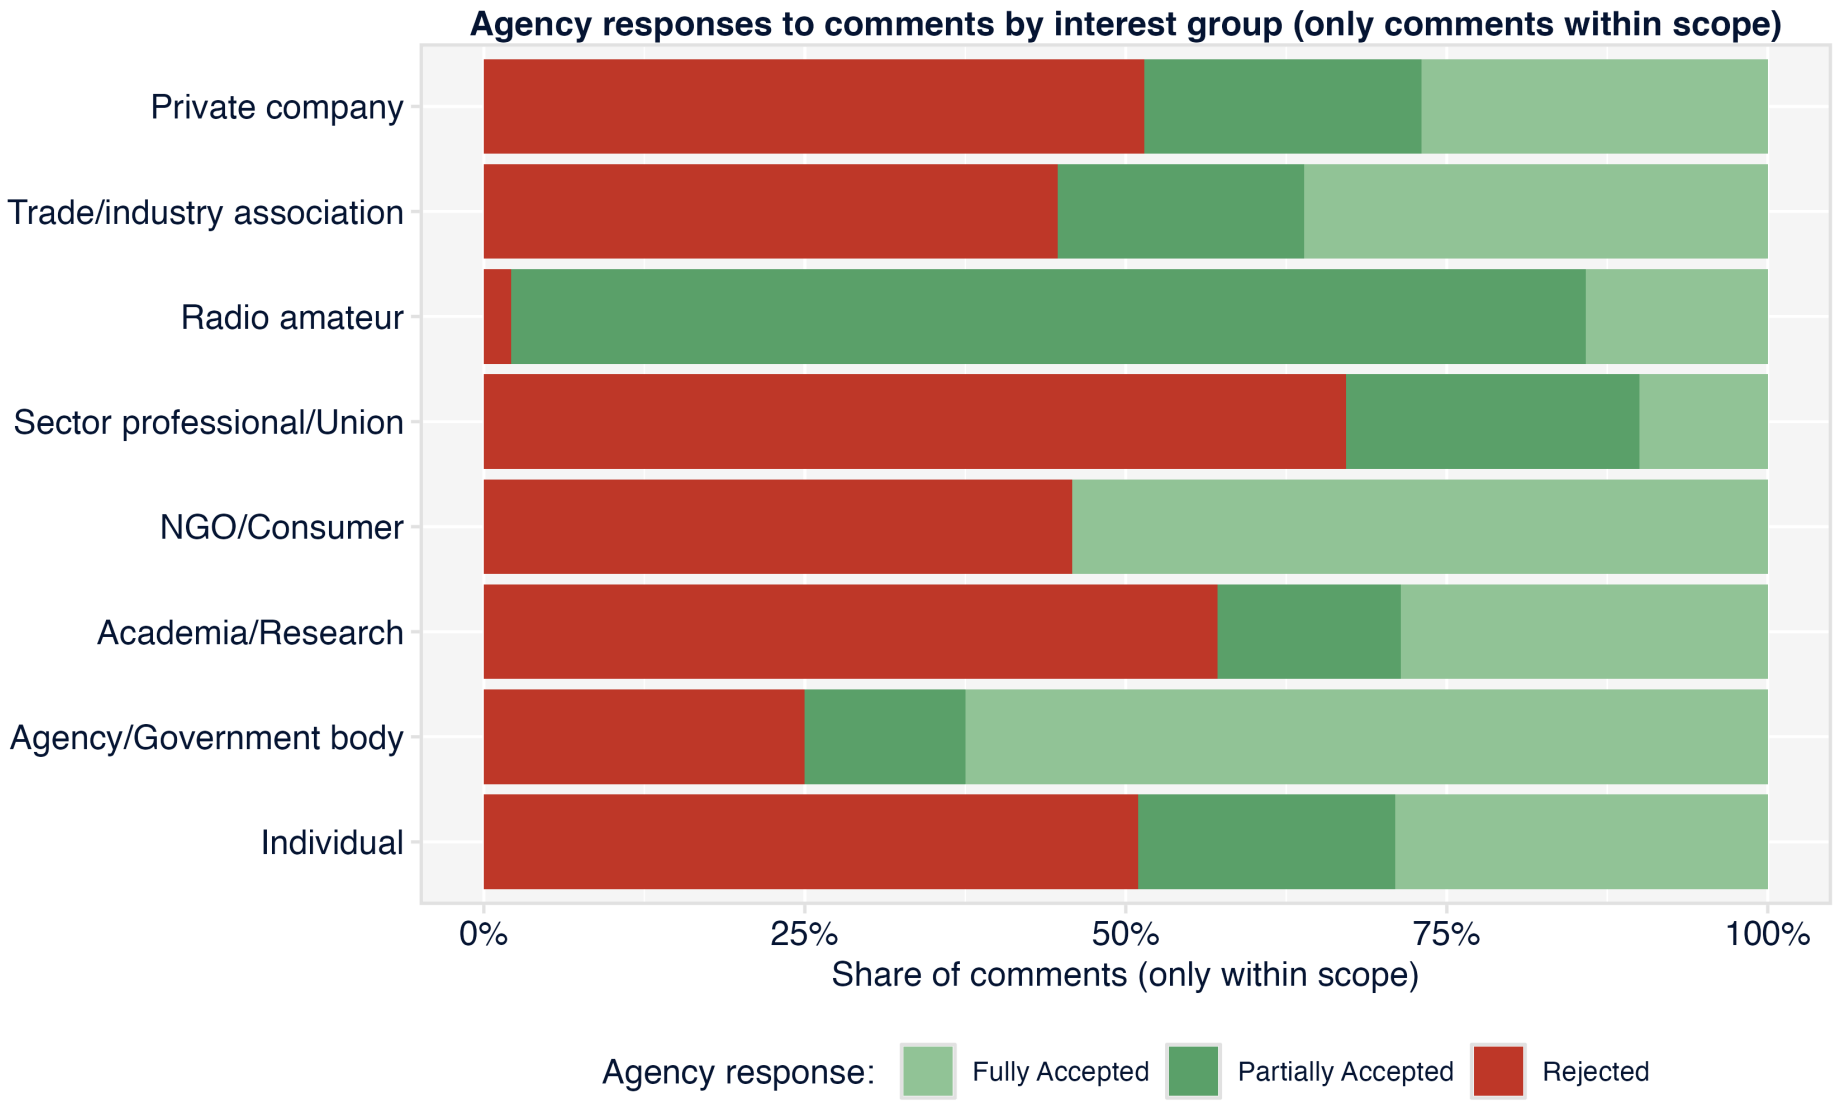
Agency responses to comments by interest group (only comments within scope)
Private company
Trade/industry association
Radio amateur
Sector professional/Union
NGO/Consumer
Academia/Research
Agency/Government body
Individual
0%
25%
50%
75%
100%
Share of comments (only within scope)
Agency response:
Fully Accepted
Partially Accepted
Rejected

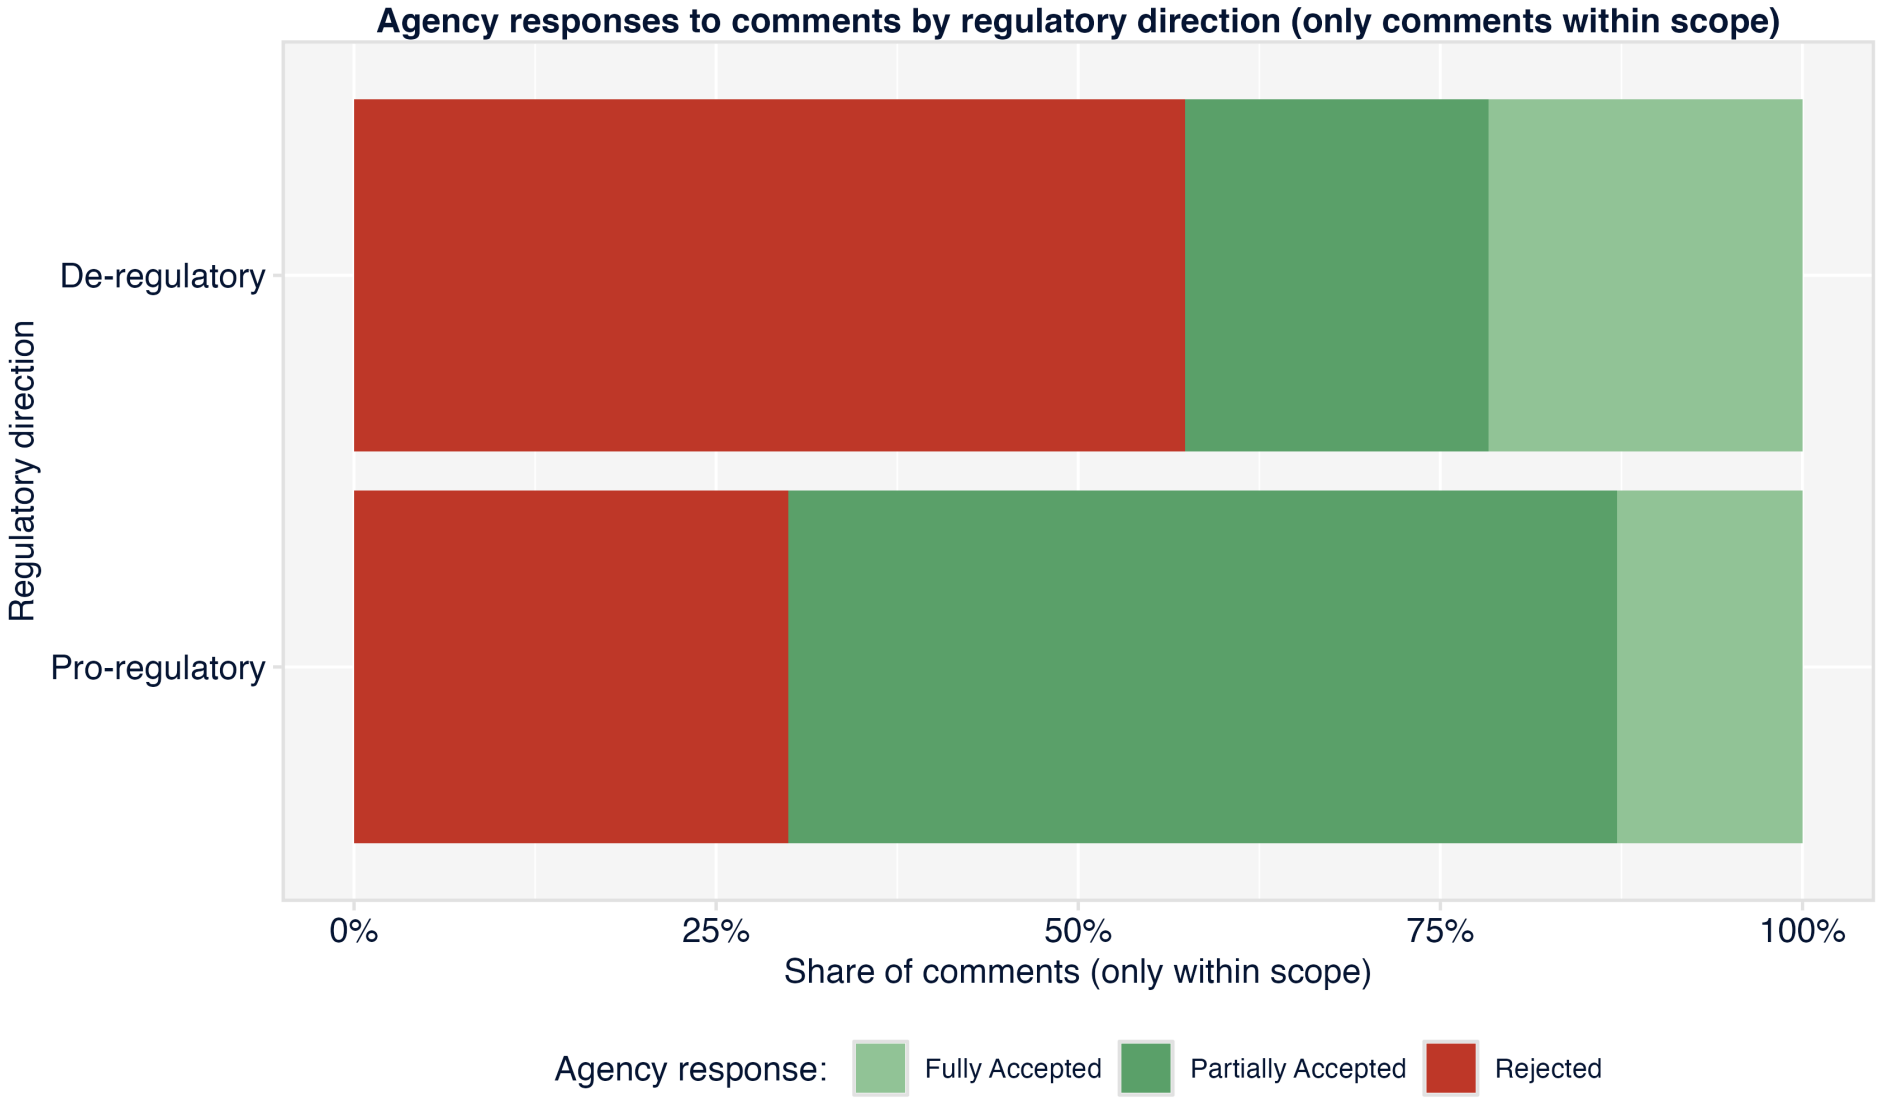
Agency responses to comments by regulatory direction (only comments within scope)
Regulatory direction
De-regulatory
Pro-regulatory
0%
25%
50%
75%
100%
Share of comments (only within scope)
Agency response:
Fully Accepted
Partially Accepted
Rejected

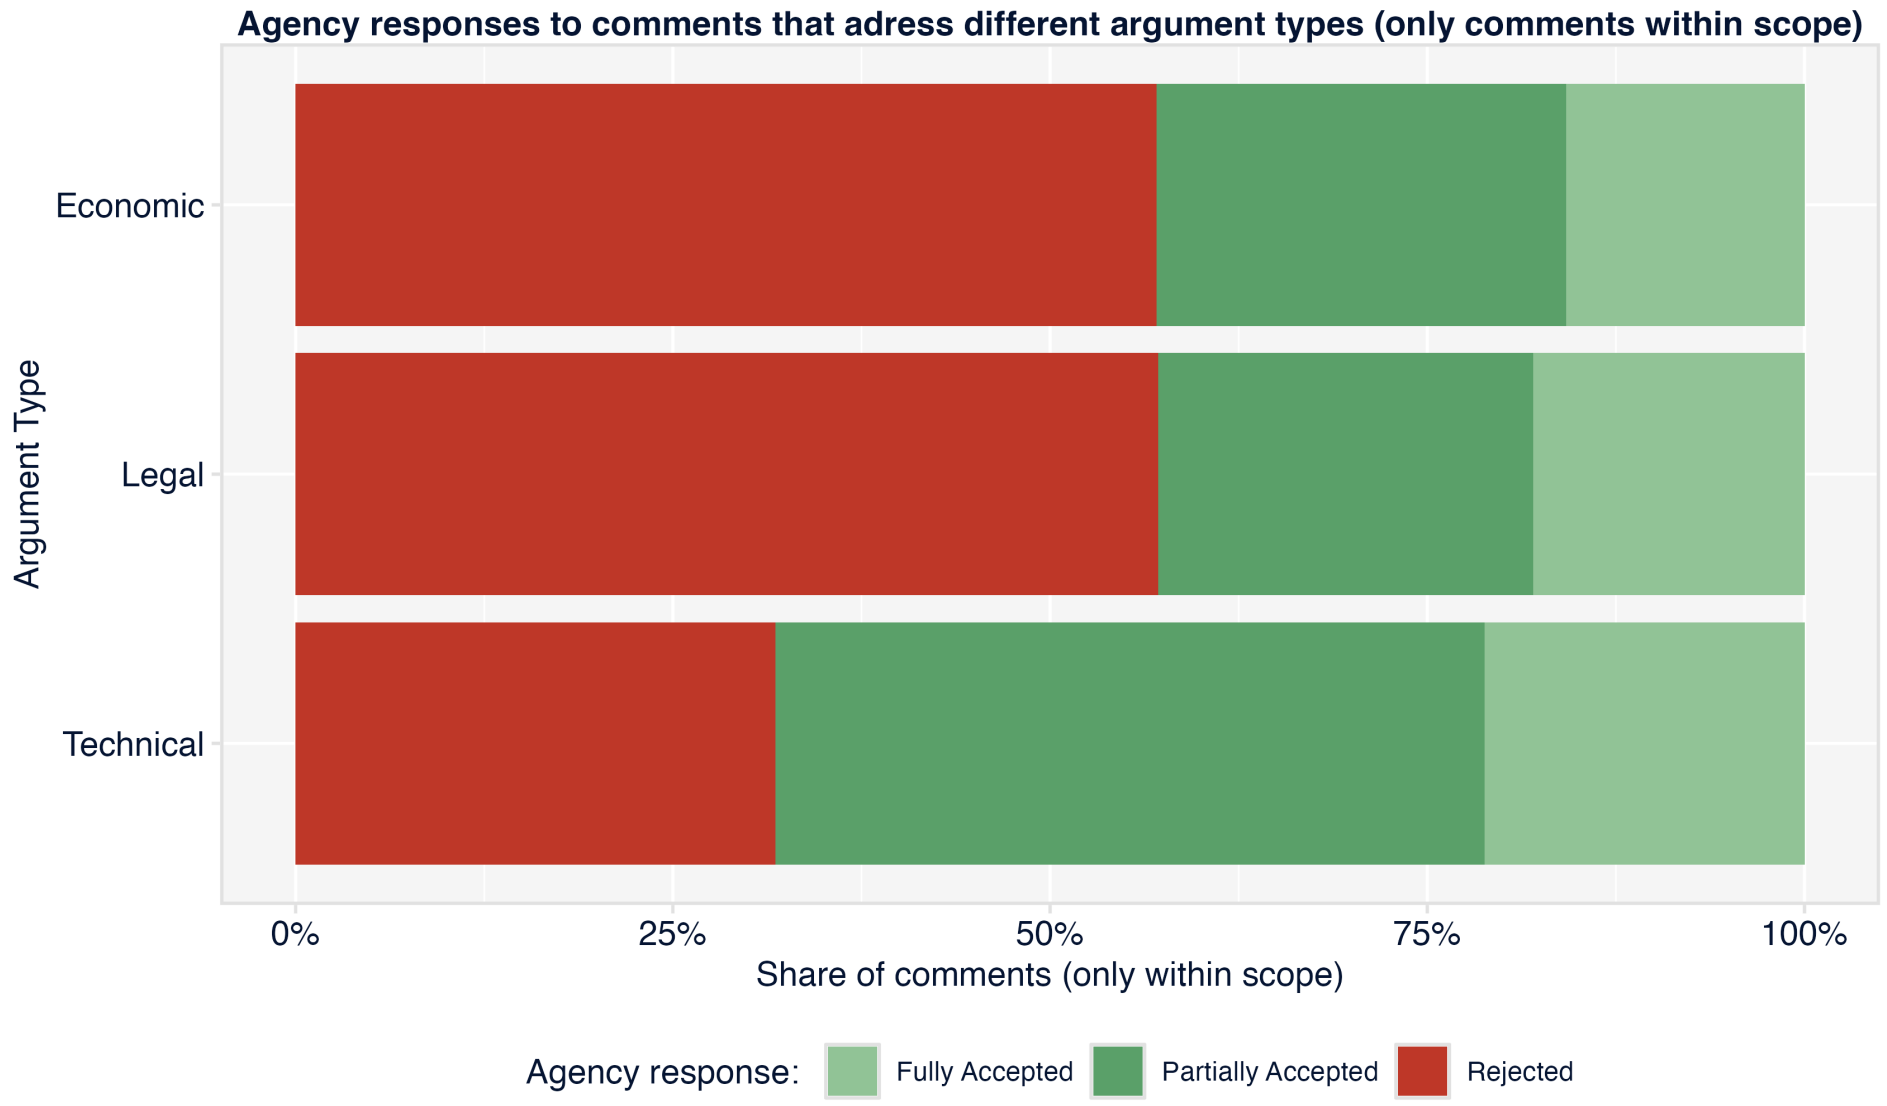
Agency responses to comments that adress different argument types (only comments within scope)
Argument Type
Economic
Legal
Technical
0%
25%
50%
75%
100%
Share of comments (only within scope)
Agency response:
Fully Accepted
Partially Accepted
Rejected

Modelos: previsão das respostas da Anatel e explicabilidade do impacto por grupos de interesse

Modelos preditivos e explicativos utilizados na tese

- **Modelos Preditivos**: prever a resposta da Anatel às contribuições. Duas tarefas:
  - Classificação do escopo.
  - Classificação do impacto (com 2 agrupamentos distintos dos dados).
- **Modelos Explicativos**: verificar o peso de variáveis de identidade vs. variáveis de conteúdo das contribuições no escopo e no impacto.
  - Sequência de 10 modelos distintos para avaliar como diferentes características afetavam o impacto.

Table 5 – Performance of predictive models on the scope classification task (validation scores)

Algorithm	Accuracy of different text representations			Best F1 Score (Macro)
	TF-IDF	BERT	GPT-3	
Decision Tree	0.76	0.75	0.75	0.76
Logistic Regression	0.76	0.8	0.85	0.85
Random Forest	0.82	0.82	0.83	0.83
AdaBoost	0.8	0.81	0.86	0.86
MLP Classifier	0.8	0.82	0.87	0.87
K-Nearest Neighbors	0.83	0.82	0.89	0.89
Support Vector Machine	0.8	0.85	0.89	0.89

Table 6 – Performance of predictive models on the impact classification task (validation scores)

Algorithm	Accuracy of different text representations			Best F1 Score (Macro)
	TF-IDF	BERT	GPT-3	
Separated grouping (Fully accepted vs. Rejected) -> N = 2570				
Decision Tree	0.71	0.68	0.68	0.71
Logistic Regression	0.73	0.77	0.8	0.8
Random Forest	0.75	0.78	0.82	0.82
AdaBoost	0.73	0.73	0.77	0.77
MLP Classifier	0.76	0.8	0.83	0.83
K-Nearest Neighbors	0.75	0.77	0.83	0.83
Support Vector Machine	0.76	0.8	0.84	0.84
Combined grouping (Fully and partially accepted vs. Rejected) -> N = 4074				
Decision Tree	0.77	0.7	0.7	0.77
Logistic Regression	0.72	0.75	0.77	0.77
Random Forest	0.78	0.78	0.79	0.79
AdaBoost	0.74	0.74	0.78	0.78
MLP Classifier	0.77	0.79	0.79	0.79
K-Nearest Neighbors	0.75	0.77	0.82	0.82
Support Vector Machine	0.79	0.79	0.83	0.83

Modelos explicativos: sequência de especificações

Table 7 – Sequence of explanatory models (scope and impact)

Model	Specification
M0	Interest Groups (Identity)
M1	Identity + Embeddings (PCA components)
M2	Embeddings
M3	Content Variables (argument types + regulatory direction)
M4	Embeddings + content variables
M5	Identity + Embeddings + Content Variables
M6	Identity + Predicted Probabilities
M7	Predicted Probabilities
M8	Predicted Probabilities + Content Variables
M9	Identity + Predicted Probabilities + Content Variables

Performance dos modelos explicativos (impacto)

Table 12 – Performance of the explanatory models for impact

Model	Description	AIC	McFadden R2	Tjur R2	AUC
M0	Identity	4914.011	0.133	0.153	0.661
M1	Identity + Embeddings	3691.218	0.385	0.438	0.875
M2	Embeddings	3706.638	0.379	0.433	0.872
M3	Content Variables	5130.330	0.095	0.126	0.706
M4	Embeddings + Content	3711.236	0.382	0.435	0.874
M5	Identity + Embeddings + Content	3694.975	0.387	0.441	0.876
M6	Identity + Predicted Probabilities	1559.914	0.727	0.798	0.975
M7	Predicted Probabilities	1559.300	0.725	0.798	0.976
M8	Predicted Probabilities + Content	1565.010	0.727	0.799	0.976
M9	Identity + Predicted Probabilities + Content	1568.222	0.729	0.799	0.976

Voltando ao problema metodológico...

Takeaways para o grupo

- Trate IA como **medição**: defina categorias, avalie, audite e documente
- Combine abordagens: embeddings/classificadores para escala + LLM para tarefas abertas
- Prompting pode ser uma ferramenta de pesquisa subestimada! Muito efetiva em alguns casos e não necessita de tanta expertise técnica.
    - No entanto, fine tuning ainda é o estado da arte para tarefas técnicas complexas em que se exige alta acurácia.
- Publicar: métricas, procedimentos e limites é tão importante quanto o resultado

Obrigado!